FERRAMENTA DE TRATAMENTO DE IMAGEM UTILIZANDO IA PARA IDENTIFICAR AGLOMERAÇÃO DE AVES CONFINADAS

Jhonny Mezzari Bif[1], Sergio Coral[2]

Resumo: Deve ter uma sequência de frases concisas e objetivas em parágrafo único, sem enumeração de tópicos, de 100 a 250 palavras, seguido, logo abaixo, das palavras representativas do conteúdo do trabalho, isto é, palavras-chave e/ou descritores, conforme a **??**).

Palavras-chave: Elemento obrigatório. Devem ser separadas entre si por ponto e vírgula e finalizadas por ponto, com as iniciais em letra minúscula, com exceção dos substantivos próprios e nomes científicos.

ABSTRACT: Tradução do resumo em língua vernácula para outro idioma de propagação internacional (em inglês ABSTRACT, em francês RESUMÉ, em espanhol RESUMEN).

Keywords: keyword 1; keyword 2; keyword 3.

1 INTRODUÇÃO

========== Vai pra algum luggar ainda, estava no trabalho proposto

O trabalho foi proposto pelo desenvolvimento de um sistema que utilizou inteligência artificial, com o objetivo de identificar de maneira automática as aglomerações dos frangos utilizando imagens de câmeras que estavam instaladas dentro de um aviário. Dessa forma, foi possível identificar as regiões com maior concentração de frangos, o que contribuiu para a prevenção de situações que poderiam comprometer o bem-estar animal.

O objetivo foi implementar um modelo computacional capaz de analisar imagens e detectar áreas com ocorrência de aglomeração. Além disso, buscou-se que o processamento dos dados ocorresse de forma dinâmica, visando reduzir ou até eliminar a necessidade de armazenamento

[1]Curso de Ciência da Computação, Universidade do Extremo Sul Catarinense (Unesc), jhonnybif@unesc.net

[2]Orientador. Curso de Ciência da Computação, Universidade do Extremo Sul Catarinense (Unesc), sergiocoral@unesc.net

físico. Por fim, pretendeu-se apresentar ao produtor os resultados da análise de maneira simples e acessível. ==========

A produção avícola desempenha um papel de destaque na economia brasileira. Em 2023, o Brasil firmou-se como o segundo maior produtor de carne de frango do mundo, atrás apenas dos Estados Unidos, e liderou as exportações globais, chegando a ultrapassar as 5 milhões de toneladas comercializadas, gerando uma receita superior a 9 bilhões de dólares (ABPA, 2024). Este cenário reforça a importância de práticas que assegurem não apenas a produtividade, mas também o bem-estar dos animais.

Dentre os variados desafios enfrentados pela avicultura moderna, destaca-se a ocorrência de aglomerações de frangos nos ambientes confinados. No que pode resultar em sufocamento e mortalidade significativa, especialmente quando associado a fatores como pânico, superlotação em áreas ou repetições comportamentais recorrentes (Subedi et al., 2023). A detecção antecipada e o monitoramento eficiente desses eventos tornam-se elementos fundamentais tanto para a redução de perdas econômicas quanto para a melhoria do bem-estar animal.

Com os recentes avanços da inteligência artificial (IA) e visão computacional, tornou-se viável desenvolver sistemas capazes de identificar padrões comportamentais anormais em tempo real. Tecnologias baseadas em redes neurais convolucionais (CNN), como as implementadas em arquiteturas do tipo YOLO, já demonstraram alto desempenho na detecção e classificação de objetos (Elmessery et al., 2023). Além disso, abordagens integradas à Internet das Coisas (IoT) têm sido aplicadas com sucesso no monitoramento de condições ambientais e na análise do comportamento das aves, com impactos positivos na produtividade e na saúde dos animais (Santos et al., 2023).

Recentemente, o uso de tecnologias de visão computacional associadas ao aprendizado profundo tem se destacado de forma promissora para o monitoramento automatizado de frangos em ambientes confinados. Sendo assim, é possível identificar comportamentos anormais, como a formação de aglomerações, que muitas vezes resultam em sufocamento e aumento na taxa de mortalidade dos frangos (Yang et al., 2024a). Esses comportamentos, geralmente relacionados ao estresse, preferência por zonas aquecidas ou reações de pânico, comprometem significativamente tanto o bem-estar animal quanto a produtividade das granjas. A aplicação de redes neurais convolucionais (CNN) nesse caso pode auxiliar na tomada de de-

cisão baseada em evidências, minimizando falhas humanas e promovendo um manejo mais eficiente e ético (Neethirajan, 2022).

O objetivo principal deste trabalho é implementar um sistema de visão computacional para detectar aglomerações de aves, contribuindo para a melhoria do bem-estar animal e para a eficiência produtiva. Para atingir esse objetivo, busca-se compreender os comportamentos de aglomeração dos frangos, interpretar os resultados gerados pela inteligência artificial, analisar os testes realizados e avaliar a eficácia do modelo de detecção por meio de indicadores como acurácia, precisão e recall na identificação de aglomerações.

O Deep Learning, um método de Machine Learning, está se tornando uma ferramenta essencial para analisar e identificar padrões em conjuntos de dados grandes e complexos. Em estudos sobre o comportamento animal, o Deep Learning tem sido de grande ajuda ao fornecer uma compreensão detalhada das ações dos animais. Na avicultura, ele oferece uma ferramenta poderosa para observar e rastrear de perto as atividades. (Yang et al., 2024b).

A cadeia produtiva avícola está consolidada no mercado, com um avanço constante há mais de 10 anos. (Lamarca et al., 2018). Com isso, sistemas de medição automatizados se tornam cada vez mais essenciais para monitorar e promover o bem-estar na crescente indústria aviária. Os avanços tecnológicos das últimas décadas têm impulsionado o desenvolvimento de sistemas de rastreamento animal por meio de imagens digitais automatizadas e precisas, ampliando sua aplicação e eficácia. (Yang et al., 2024a).

Dessa forma, as granjas avícolas a atenção com os frangos em relação à saúde, atividades e padrões comportamentais é essencial. Com os recursos de detecção da inteligência artificial, podem identificar os sinais da aglomeração, chegando a reconhecer mudanças sutis em seus comportamentos, auxiliando os produtores a agir corretamente e também evitando falhas humanas ao não conseguir identificar e/ou não ter a necessidade de ficar observando os frangos. Dessa forma, além de prover um bem-estar melhor para as aves, a tecnologia também pode prevenir prejuízos econômicos significativos.

Este trabalho está organizado em cinco capítulos. A Seção 1, Introdução, apresenta o tema do trabalho, seus objetivos geral e específicos, a justificativa da escolha do tema e a metodologia adotada para condução da pesquisa.

=== refazer ESTRUTURA===

A Seção 2, Fundamentação Teórica, reúne os conceitos técnicos e científicos que embasam o projeto, incluindo os tópicos de visão computacional, redes neurais convolucionais (CNN), Internet das Coisas (IoT) aplicadas à avicultura, e o comportamento animal relacionado ao bem-estar das aves. A Seção 3, Trabalhos Correlatos, aborda estudos e pesquisas anteriores que utilizaram inteligência artificial para o monitoramento de aves, destacando diferentes abordagens, algoritmos e métricas de desempenho utilizadas. A Seção 4, Trabalho Proposto, descreve o sistema desenvolvido para identificar aglomerações de frangos confinados, apresentando os objetivos da aplicação, sua estrutura funcional e os critérios de validação por meio de testes com registros reais de aviários. Por fim, a Seção 5, Metodologia, detalha o tipo de pesquisa, os métodos utilizados para coleta e análise de dados, os recursos materiais e humanos empregados no desenvolvimento, além do cronograma de execução das atividades.

2 TRABALHOS CORRELATOS

Não há tantos trabalhos sobre detecções aglomerações de frangos confinados utilizando inteligencia artificial publicados, mas podemos encontrar os publicados em periódicos, como por exemplo ScienceDirect e IEEE Xplore. O estudo (Paneru et al., 2025) aplicou métodos de deep learning para identificação automática de galos e galinhas em ambientes livres de gaiola, com foco em características fenotípicas como tamanho da crista e dimensões corporais. Foram utilizadas variantes dos modelos YOLOv5u e YOLOv11, treinadas com conjuntos de imagens coletadas em instalações de pesquisa com seis galos e duzentas galinhas da linhagem Lohmann LSL Lite. Os resultados mostraram que as variantes YOLOv5lu e YOLOv11x apresentaram os melhores desempenhos na detecção baseada no tamanho da crista, alcançando precisão de 87,7% e 86,7%, respectivamente, enquanto as variantes YOLOv5xu e YOLOv11m se destacaram na detecção baseada no tamanho corporal, com precisão de até 89% e mAP@0.50 superior a 82%. O trabalho demonstrou que técnicas de visão computacional podem ser aplicadas com sucesso para o monitoramento automático do comportamento e seleção de reprodutores, contribuindo para práticas de manejo mais precisas e sustentáveis na avicultura.

A pesquisa (Guo et al., 2025) apresenta o PCCNet, uma rede densa supervisionada por pontos para contagem de frangos de corte em ambientes de alta densidade, com o objetivo de aprimorar a eficiência pro-

dutiva e o bem-estar animal. O estudo propõe um modelo que utiliza pontos como alvos de aprendizado, permitindo identificar e quantificar aves com maior precisão, mesmo em condições de sobreposição e aglomeração. A arquitetura incorpora um módulo de fusão de informações contextuais (CIFF), que combina características em múltiplas escalas, e o KMO matcher, responsável por aprimorar o pareamento entre pontos previstos e reais, reduzindo ambiguidades e melhorando a convergência do modelo. Para validação, foi desenvolvido o Chicken Counting Dataset (CCD), dividido em dois subconjuntos conforme a idade das aves (CCD_A e CCD_B), contendo 827 imagens anotadas. Os resultados experimentais demonstraram alta acurácia, com 97,85% e 97,06% de precisão nos subconjuntos CCD_A e CCD_B, e erros médios absolutos (MAE) de 1,966 e 5,173, respectivamente, superando métodos recentes baseados em mapas de densidade e frameworks supervisionados por pontos. Além disso, o PCCNet manteve desempenho robusto sob diferentes condições de iluminação e densidade, mostrando potencial para aplicação em granjas comerciais e extensibilidade para outras espécies aviárias.

Segundo (Yang et al., 2024a) onde foram desenvolvidos modelos de redes neurais convolucionais (CNN) para monitorar o índice de atividade de galinhas poedeiras em sistemas livres de gaiola, com o objetivo de avaliar o bem-estar e a saúde do plantel. Utilizando um conjunto de 1.500 imagens de vista superior, foram treinados e comparados seis modelos baseados em YOLOv5, YOLOv8, ByteTrack, DeepSORT e StrongSORT. A combinação de YOLOv8 com DeepSORT apresentou o melhor desempenho, com precisão de rastreamento (MOTA) de 94%. O modelo permitiu quantificar a atividade das aves em três níveis (baixo, médio e alto) e detectar comportamentos anormais, como sufocamento e empilhamento, demonstrando o potencial da visão computacional no acompanhamento da saúde avícola.

3 MATERIAIS E MÉTODOS

A partir desta pesquisa, que é de categoria quantitativa e aplicada, foi desenvolvida e validada uma ferramenta baseada em inteligência artificial, destinada à identificação de aglomerações de frangos confinados. Ela objetivou oferecer uma solução computacional e prática para um problema real do setor, sendo avaliada por meio da análise de métricas de desempenho da IA, como acurácia, precisão e recall.

Para a realização do trabalho, foi utilizado dois modelos de câmera para a captação de imagens, sendo no aviário A uma XM535 X6E

WEQ de 4 Megapixels, e no aviário B uma Intelbras VIP 1430 D G2 de 4 Megapixels, um computador equipado com processador Ryzen 7 5700x, 32 GB de memória RAM e uma placa de vídeo RTX 4060 Ti 8gb e Windows 11 Pro, destinado à execução do treinamento e dos testes. Na parte do software, utilizou-se o Visual Studio Code como interface para programação, além do Python com Flask para a utilização do YOLO e para o backend, enquanto o frontend foi desenvolvido em Angular 17. Como ferramenta de inteligência artificial, utilizou-se o YOLO 11 na versão medium. Por fim, as imagens foram obtidas em duas granjas aviárias, que serviram como ambiente de captação dos dados.

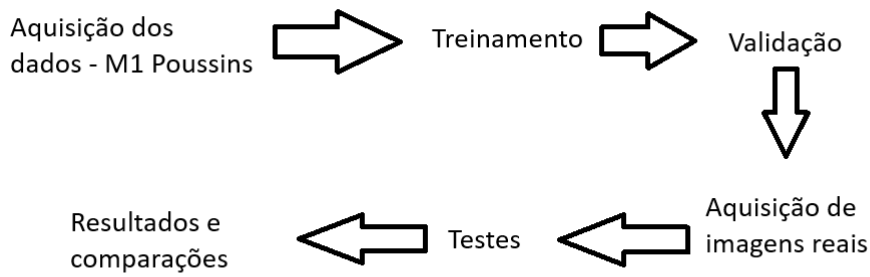
A análise dos dados foi revisada de forma quantitativa com base nas métricas geradas pelo modelo de IA, como as matrizes de confusão e as curvas de aprendizado, para base de comparação com os resultados reais, permitindo, assim, a avaliação efetiva do desempenho do sistema.

O método de coleta de dados foi obtido com gravações de vídeos que foram retirados de aviários reais, com diferentes condições de densidade populacional e comportamentais. Foram utilizados vídeos previamente gravados para que houvesse uma amostragem com diferentes níveis de idade, peso, horários, população e aglomeração.

Para validar a eficácia da ferramenta, foram realizados testes com diferentes registros do aviário. Os resultados obtidos foram avaliados com base em métricas como acurácia, precisão e recall, a fim de medir o desempenho do sistema na identificação de aglomerações.

A Figura 1 apresenta as etapas realizadas para o desenvolvimento desta pesquisa, sendo elas: aquisição do dataset, treinamento do Yolo 11m, validação do dataset, aquisição das imagens reais, testes e, por fim, os resultados e comparações.

Figura 1 - Etapas dos dados



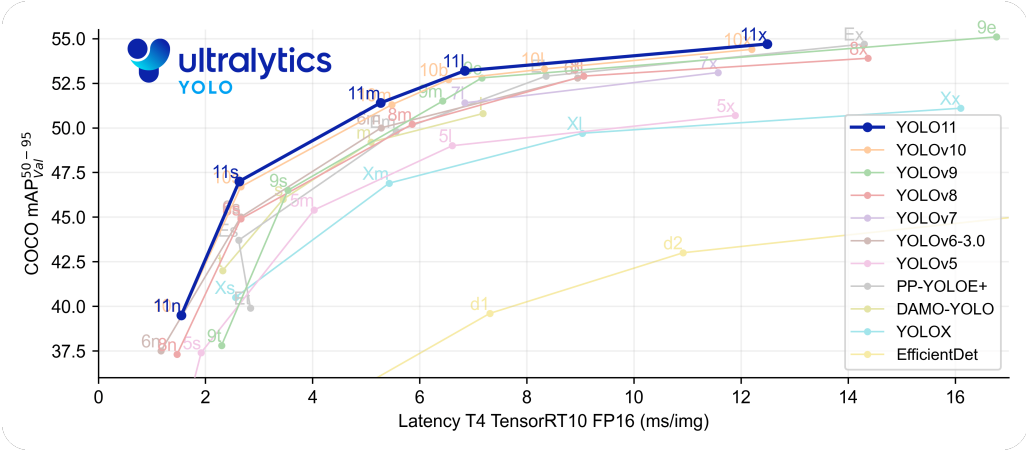
Fonte: Do autor.

3.1 YOLO - YOU ONLY LOOK ONCE

Entre os principais avanços na detecção de objetos em tempo real está a arquitetura *YOLO* onde o desempenho está fortemente baseado no uso de CNN. Diferente dos métodos comuns de detecção, que dividem a tarefa em duas etapas, primeiro localizando regiões de interesse e depois classificando os objetos, já o *YOLO* reformulou o problema como uma única tarefa de regressão. Ele divide a imagem em uma grade e, para cada célula, prevê diretamente a presença de objetos, suas coordenadas e probabilidades de classe, tornando o processo extremamente rápido e eficiente. A base do *YOLO* é uma CNN profunda, que processa a imagem de entrada extraindo características visuais relevantes, permitindo que o modelo identifique e localize objetos simultaneamente (Jocher; Qiu, 2024).

Com sucessivas melhorias, arquiteturas integraram técnicas mais avançadas, aprimoramento na normalização dos dados e uso de *anchor boxes*, garantindo maior precisão e robustez no reconhecimento de objetos. Neste trabalho foi utilizada a versão mais recente (primeiro semestre de 2025), o *YOLO11m*, por apresentar aprimoramentos significativos em velocidade, precisão e estabilidade em relação às versões anteriores, como podemos ver na Figura 2 (Jocher; Qiu, 2024).

Figura 2 - Comparação de performance Yolo 11



Fonte: (Jocher; Qiu, 2024).

3.2 CONJUNTO DE DADOS

O conjunto de dados utilizado para o treinamento desta pesquisa foi Project M1 Poussins Computer Vision Model (projetM1Poussins, 2024), que possui a licença *Public Domain* no qual se trata de domínio público, está disponível na plataforma Roboflow Universe (Dwyer et al., 2024). O Conjunto é constituído de apenas uma classe e totaliza 563 imagens, sendo 438 para treinamento, 81 para validações e outras 44 para testes.

3.3 ARQUITETURA

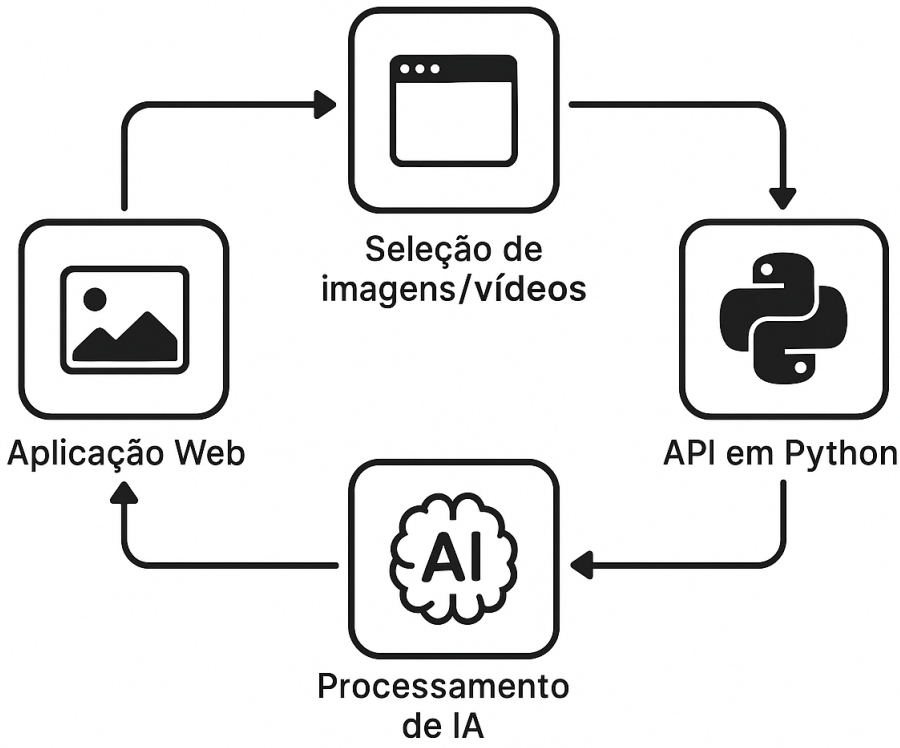
A Figura 3 apresenta a arquitetura geral desenvolvida nesta pesquisa. O processo inicia-se na aplicação web, responsável por receber do usuário um arquivo de imagem ou vídeo. Em seguida, é selecionado o método de detecção desejado e, após a confirmação do envio, um modal é exibido para inserção das dimensões reais da área captada pela câmera (em metros) e da idade das aves. Esses dados são então enviados para a *API*, onde ocorre o processamento das informações. A etapa inicial do processamento consiste na detecção das aves por meio de um modelo de visão computacional baseado em redes neurais, responsável por identificar os frangos e retornar as respectivas *bounding boxes*.

A partir dessas delimitações, calcula-se o ponto central de cada ave e aplica-se a transformação de homografia para projetar esses pontos no plano real, possibilitando a criação de uma malha espacial dividida em áreas equivalentes a $1m^2$. Em cada célula dessa malha é realizada a contagem de aves, sendo os valores comparados aos limites máximos de ocupação estabelecidos de acordo com a idade e o peso das aves, conforme diretrizes da Embrapa (Figueredo, 2022).

Quando o número de aves em uma célula ultrapassa o valor limite, essa área é marcada como aglomeração. Paralelamente, é gerado um mapa de calor para representar visualmente o grau de densidade das aves, utilizando uma escala cromática que varia do verde (baixa densidade) ao vermelho (alta aglomeração).

Ao final do processamento, a *API* retorna à aplicação web os vídeos com a malha de distribuição espacial e o mapa de calor, acompanhados das métricas calculadas, permitindo ao usuário analisar os resultados de forma clara e objetiva.

Figura 3 - Arquitetura simplificada da pesquisa



Fonte: Do autor.

4 RESULTADOS E DISCUSSÃO

Para Avaliação dos resultados obtidos nesta pesquisa, partiremos de dois pontos sobre o modelo desenvolvido, primeiramente foram avaliados os resultados do conjunto de dados, onde temos as métricas de detecção das aves, posteriormente será exibido do desempenho da ferramenta completa.

4.1 CONJUNTO DE DADOS

Com o modelo pré-treinado na plataforma do Roboflow utilizando o yolov8s (Yolo version 8 small) ele obteve as seguintes métricas *MAP@50* de 84.7%, Precisão de 79.8% e *Recall* de 78.9%. Foi realizado localmente dois treinamentos, ambos utilizando o Yolo11m (Yolo 11 medium), mantendo a configuração padrão de treinamento, alterando somente a quantidade de épocas, sendo 400 épocas com uma paciência de 80, ou seja caso ele não evolua em 80 épocas ele para o treinamento e o de 1000 épocas com 400 de paciência, o melhor resultado no treinamento de 400 épocas foi na 150 fazendo com que ele tenha parado na 230 pois ele não evolui nas 80 épocas, já no treinamento de 1000 épocas o melhor resultado atingido foi na época 990, os resultados do treinamento na Tabela 1 abaixo.

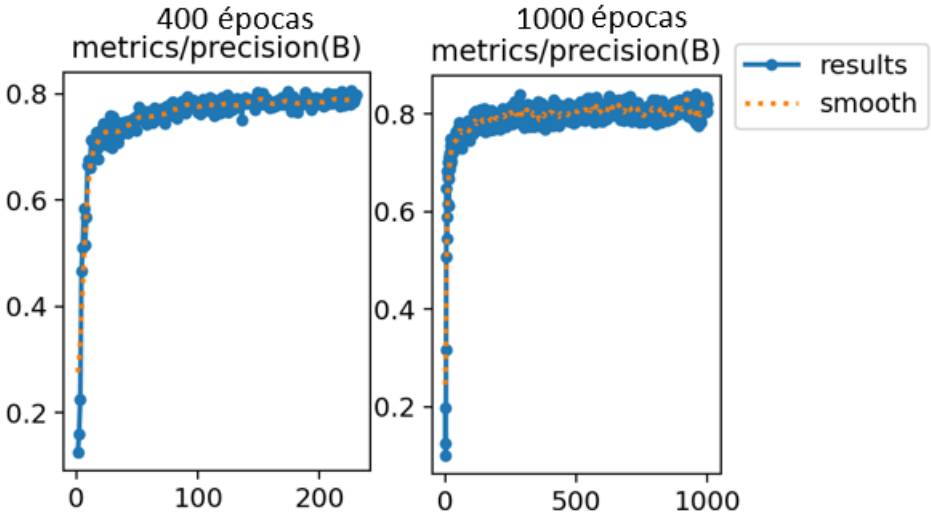
Tabela 1 - Treinamento do Conjunto de dados

Treinamento do Conjunto de dados M1 poussins					
Épocas	**F1 Score**	**mAP50**	**Recall**	**Precisão**	**mAP50-95**
400	0.783	0.833	0.773	0.794	0.430
1000	0.778	0.830	0.735	0.828	0.444

Fonte: Do autor.

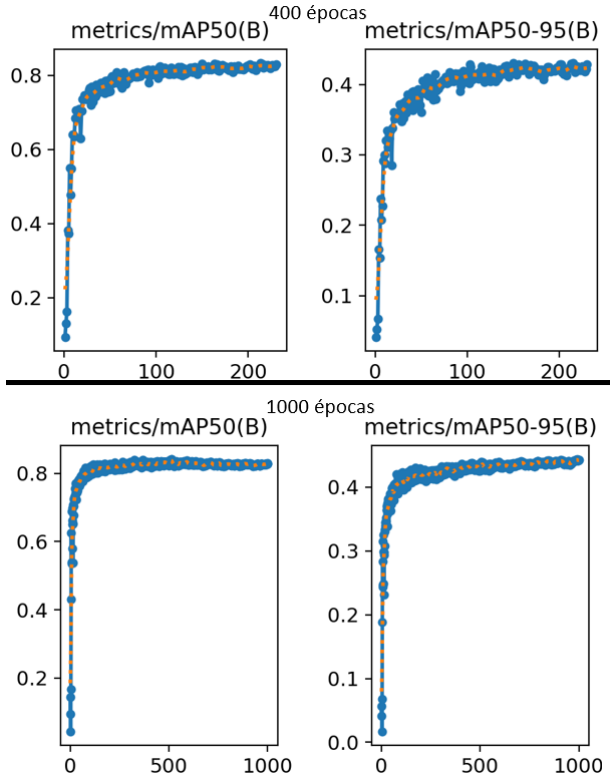
Abaixo na Figura 4 e 5, temos as métricas de de precisão e mAP50, levando em consideração a métrica de mAP50, no treinamento de 400 épocas ele estabilizou a cima de 0.800 após a época 80 e precisão a cima de 0.750 após a época 63. Já no treinamento de 1000 épocas ele estabilizou a 0.800 também após a época 80, e precisão a cima de 0.750 após a época 52, oque nos mostra que método de treinamento do Yolo consegue se manter constante no seu treinamento.

Figura 4 - Métricas de precisão geradas no Treinamento



Fonte: Do autor.

Figura 5 - Métricas de mAP50 e mAP50-95 geradas no Treinamento



Fonte: Do autor.

Após o treinamento realizado, utilizamos o método de validação que o Yolo nos proporciona juntamente com as 81 imagens que o dataset nos fornece, segue a Tabela 2 abaixo.

Tabela 2 - Validação do Conjunto de dados

Validação do Conjunto de dados M1 poussins					
Épocas	**F1 Score**	**mAP50**	**Recall**	**Precisão**	**mAP50-95**
400	0.773	0.804	0.720	0.835	0.450
1000	0.780	0.811	0.735	0.827	0.466

Fonte: Do autor.

Com a validação concluída, foi realizado o método de teste que o Yolo nos fornece, com as 41 imagens de testes que o dataset nos disponibiliza. Segue a Tabela 3 abaixo com os resultados.

Tabela 3 - Teste do Conjunto de dados

Teste do Conjunto de dados M1 poussins					
Épocas	**F1 Score**	**mAP50**	**Recall**	**Precisão**	**mAP50-95**
400	0.788	0.808	0.746	0.837	0.450
1000	0.791	0.819	0.768	0.817	0.450

Fonte: Do autor.

Após a analise dos resultados de treinamento, validação e teste do conjunto foi escolhido dar prosseguimento a pesquisa com o conjunto de dados que foi treinado por 1000 épocas.

4.2 LÓGICA DA AGLOMERAÇÃO

Como base para a lógica da detecção de aglomeração foi utilizado o modo *predict* do Yolo 11, onde este método apenas localiza e nos entrega a localização dos frangos, a Figura 6 abaixo, foi extraída de um vídeo com 22 frames, onde ele detectou uma média de 229 frangos, estando configurado para detectar apenas frangos com a confiança acima de 0.7.

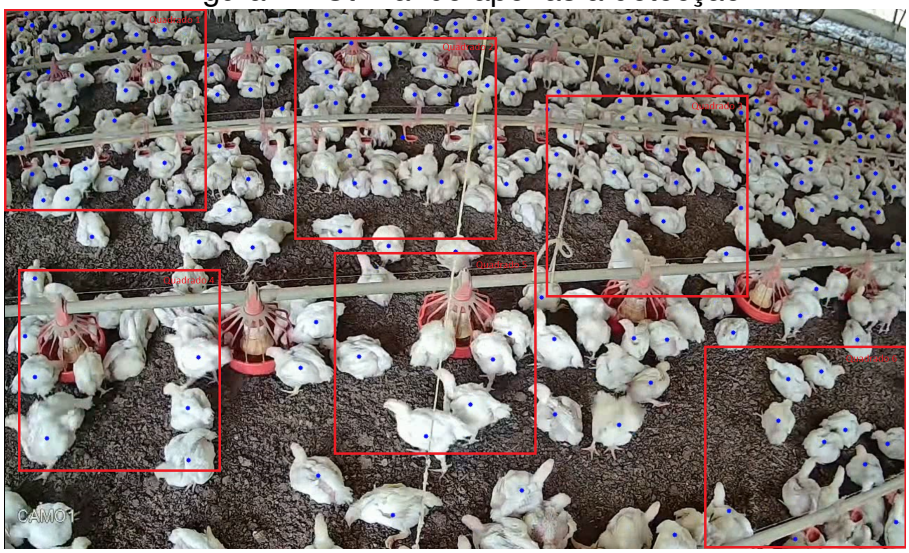
Figura 6 - Utilizando apenas a detecção



Fonte: Do autor.

Para realizarmos as métricas utilizamos a seguinte Figura 8, sendo definidos seis quadrados aleatoriamente na imagem de tamanho 400x400 px cada, assim podemos ter métricas aproximadas.

Figura 7 - Utilizando apenas a detecção



Fonte: Do autor.

Como foi realizado essa contagem, cada quadrado foram dividido em métricas, Total que é a quantidade total de frangos dentro do quadrado, Encontrado que é oque o Yolo identificou, Falsos oque o Yolo identificou e não era frango, dados na Tabela 4 abaixo.

Tabela 4 - Métricas aproximadas dos quadrados de contagem

Métricas aproximadas dos quadrados de contagem				
Quadrado	**Total (Real)**	**Encontrado(TP)**	**Falsos(FP)**	**FN**
Q1	79	37	0	42
Q2	39	23	1	16
Q3	35	21	0	14
Q4	17	7	0	10
Q5	7	5	0	2
Q6	14	10	0	4
Total	191	103	1	88

Fonte: Do autor.

A precisão indica a proporção de detecções corretas (TP) entre todas as detecções feitas (TP + FP). No exemplo, 103 detecções corretas de 104 totais resultaram em 0.990, mostrando alta confiabilidade nas predições positivas.

$$Precision = \frac{TP}{TP + FP} = \frac{103}{103 + 1} = \frac{103}{104} = 0.990$$

O recall mede a proporção de frangos corretamente identificados (TP) sobre todos os frangos reais (TP + FN). Aqui, 103 frangos detectados corretamente de 191 totais deram 0.539, indicando que nem todos os frangos foram capturados.

$$Recall = \frac{TP}{TP + FN} = \frac{103}{103 + 88} = \frac{103}{191} = 0.539$$

A acurácia amostral mostra a fração de predições corretas em relação ao total de casos avaliados. Com 103 acertos em 191 frangos, obtém-se 0.539, refletindo o desempenho geral do modelo na amostra.

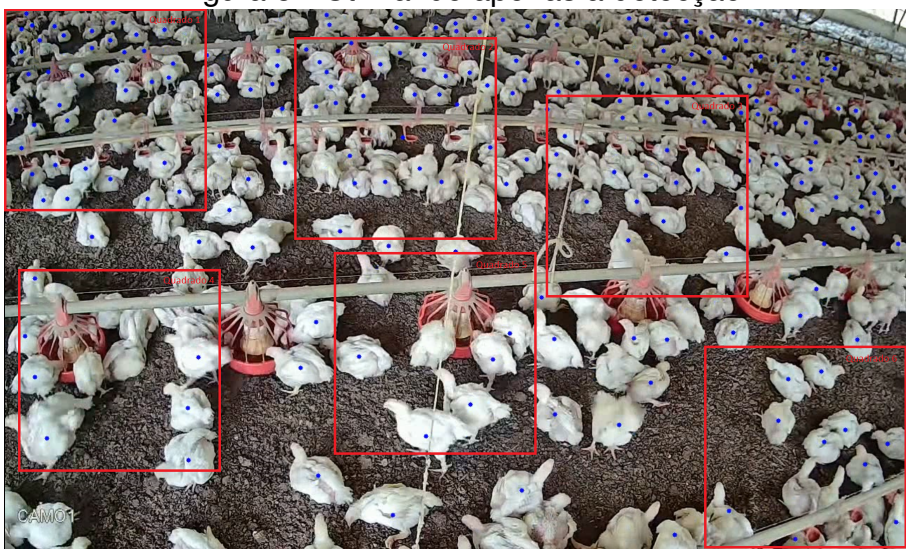
$$Acurcia\ Amostral = \frac{TP}{Total} = \frac{103}{191} = 0.539$$

O F1-Score combina precisão e recall numa única métrica balanceada, usando a média harmônica. Com os valores de precisão 0.990 e recall 0.539, o resultado de 0.695 mostra um equilíbrio entre acertos e cobertura.

$$F1{-}Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = 2 \cdot \frac{0.990 \cdot 0.539}{0.990 + 0.539} = 0.695$$

Os resultados apresentados são aproximados e refletem o desempenho do modelo na amostra avaliada: alta precisão (0.990) indica confiabilidade nas detecções positivas, recall e acurácia amostral (0.539) mostram que nem todos os frangos foram identificados, e o F1-Score (0.695) fornece uma medida balanceada entre precisão e cobertura.

Figura 8 - Utilizando apenas a detecção



Fonte: Do autor.

REFERÊNCIAS

ABPA. **Relatório Anual 2024**. 2024. Acesso em: 26 maio. 2025. Disponível em: <https://abpa-br.org/wp-content/uploads/2024/04/ABPA-Relatorio-Anual-2024_capa_frango.pdf>.

DWYER, B. et al. **Roboflow (Version 1.0) [Software]**. Roboflow, 2024. Visited on 2025-09-19. Disponível em: <https://roboflow.com>.

ELMESSERY, W. M. et al. **Yolo-based model for automatic detection of broiler pathological phenomena through visual and thermal images in intensive poultry houses**. Agriculture, 2023, v. 13, n. 8. ISSN 2077-0472.

FIGUEREDO, E. A. P. d. **Metas de desempenho para frangos de corte: Embrapa 021**. Concórdia, 2022. 24 p. Acesso em: 11 out. 2025. Disponível em: <http://www.infoteca.cnptia.embrapa.br/infoteca/handle/doc/1148818>.

GUO, Y. et al. **Pccnet: A point supervised dense chickens flock counting network**. Smart Agricultural Technology, 2025, v. 10, p. 100795. ISSN 2772-3755. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2772375525000292>.

JOCHER, G.; QIU, J. **Ultralytics YOLO11**. 2024. Disponível em: <https://github.com/ultralytics/ultralytics>.

LAMARCA, D. et al. **Climate change in layer poultry farming: Impact of heat waves in region of bastos, brazil**. Brazilian Journal of Poultry Science, 2018, Fundação de Apoio à Ciência e Tecnologia Avicolas, v. 20, n. 4, p. 657–664. ISSN 1516-635X.

NEETHIRAJAN, S. **Affective state recognition in livestock—artificial intelligence approaches**. Animals, 2022, v. 12, n. 6. ISSN 2076-2615.

PANERU, B. et al. **Deep learning methods for automatic identification of male and female chickens in a cage-free flock**. Animals, 2025, v. 15, n. 13. ISSN 2076-2615. Disponível em: <https://www.mdpi.com/2076-2615/15/13/1862>.

PROJETM1POUSSINS. Open Source Dataset, **projet M1 poussins Dataset**. Roboflow, 2024. <https://universe.roboflow.com/projetm1poussins/projet_m1_poussins>. Visited on 2025-09-17. Disponível em: <https://universe.roboflow.com/projetm1poussins/projet_m1_poussins>.

SANTOS, I. et al. **Aplicação de Internet das Coisas (IOT) e Inteligência Artificial (IA) para gestão de aviários e melhorias do desempenho produtivo: um estudo de caso em produtores de uma cooperativa agroindustrial**. Porto Alegre, RS, Brasil: SBC, 2023. 151–158 p. ISSN 2177-9724.

SUBEDI, S. et al. **Tracking pecking behaviors and damages of cage-free laying hens with machine vision technologies**. Computers and Electronics in Agriculture, 2023, v. 204, p. 107545. ISSN 0168-1699.

YANG, X. et al. **Monitoring activity index and behaviors of cage-free hens with advanced deep learning technologies**. Poultry Science, 2024, v. 103, n. 11, p. 104193. ISSN 0032-5791.

YANG, X. et al. **Deep learning methods for tracking the locomotion of individual chickens**. Animals, 2024, v. 14, n. 6. ISSN 2076-2615.